

Kullanılan Teknolojiler


Bu projede AWS'nin bulut tabanlı hizmetlerinden yararlanıldı:

- AWS Lambda: Veri işleme ve dönüştürme işlemleri
- AWS S3: Yedekleme, arşivleme ve veri paylaşımı
- AWS Glue: ETL işlemleri, Veri cataloglama ve sınıflandırma
- AWS Athena: SQL tabanlı sorgularla verilerin analizi
- Amazon QuickSight: Verilerin görselleştirilmesi ve raporlanması
- AWS IAM (Identity and Access Management): Erişim kontrolü ve güvenliği
- AWS CloudWatch: İzleme ve uyarı mekanizmaları

Programlama dili : Python

Kaynak video: https://www.youtube.com/watch?v=yZKJFKu49Dk





Kullanılan Veri Seti

- Kaggle
- YouTube'da günlük trend olan videolara ait birkaç aylık veriyi içerir
- Veri bölgeleri:
 - US, GB, DE, CA, FR (ABD, ingiltere, Almanya, Kanada, Fransa)
 - RU, MX, KR, JP, IN (Rusya, Meksika, Güney Kore, Japonya, Hindistan)
- video title, channel title, publish time, tags, views, likes and dislikes, description, and comment count
- Her bölge için farklılık gösteren category_id alanı bulunuyor. Bu alana JSON dosyalarından erişiliyor.


CA_category_id.json (7.91 kB)



CAvideos.csv (64.07 MB)




∆ video_id =	∆ title =	≜ channel_title	⇔ category_id =	☐ publish_time =	# views =	# likes
n1WpP7iowLc	Eminem - Walk On Water (Audio) ft. Beyoncé	EminemVEVO	10	2017-11- 10T17:00:03.000 Z	17158579	787425
0dBIkQ4Mz1M	PLUSH - Bad Unboxing Fan Mail	iDubbbzTV	23	2017-11- 13T17:00:00.000 Z	1014651	127794
5qpjK5DgCt4	Racist Superman Rudy Mancuso, King Bach & Lele Pons	Rudy Mancuso	23	2017-11- 12T19:05:24.000 Z	3191434	146035
d380meD0W0M	I Dare You: GOING BALD!?	nigahiga	24	2017-11- 12T18:01:41.000	2095828	132239



JSON ve CSV formatındaki verilerin S3 (Simple Storage Service) Bucket üzerinde toplanması



S3, verilerin organize edilmesi ve Data Lake katmanları arasında taşınması için kullanıldı.











AWS Glue Catalog oluşturulması



- AWS Glue Data catalog, verilerle ilgili meta verileri saklayan ve yöneten bir hizmettir.
- Glue ETL işleri, veri şemalarını tanımlamak için Data Catalog u kullanır.
- Glue Catalog, S3 veri kaynağının şemalarını, sütunlarını tanımak ve depolamak üzere kullanıldı.

Glue Crawler



 Glue Crawler ile S3 bucket taranıp JSON ve CSV dosyalarına ait şemalar çıkarıldı, ve Data Catalog üzerinde bir veritabanı ve tablolar oluşturuldu.








AWS Lambda ile verilerin standartlaştırılması


- AWS Lambda içerisinde bir fonksiyon oluşturularak ETL iş akışı gerçekleştirildi.
- JSON formatındaki veriler, Parquet formatına dönüştürülerek AWS Glue iş akışları için hazır hale getirildi.

• S3 tetikleyicisi eklenerek, Lambda fonksiyonunun S3 bucket'a yüklenen JSON verilerini otomatik olarak Parquet


formatına dönüştürmesi sağlandı.

- Veriler tekrar S3 bucket üzerinde depolandı.
- Aynı zamanda bu fonksiyon ile AWS Glue üzerinde Tablo oluşturuldu.












Glue ETL iş akışı (1)

- AWS Glue üzerinde ETL iş akışı oluşturuldu (de-on-youtube-cleansed-csv-to-parquet-rh)
- Bu ETL işi ile beraber veriler parquet formatındaki veriler üzerinde temizleme, filtreleme ve sınıflandırma işlemleri yapıldı. (Örneğin belirli bölgeler filtrelendi: ca, gb, us)
- Temizlenmiş veri Parquet formatında, region (bölge) bazlı olarak S3e kaydedildi.






• Glue Crawler ile temizlenmiş JSON ve CSV dosyalarına ait şemalar çıkarıldı, ve Data Catalog üzerinde bir veritabanı ve tablolar oluşturuldu.






 Parquet formatında filtrelenmiş/temizlenmiş iki farklı tablo var. Bu tablolar category_id alanı üzerinden birbiri ile ilişkilendirilebilir.







Athena ile verilerin analiz edilmesi

- AWS Athena ile veriler üzerinde SQL tabanlı sorgular çalıştırıldı ve analiz sonuçları verimli bir şekilde elde edildi.
- Category_id ile ilintili olan iki tablo SQL komutları ile analiz edildi.




- 1 SELECT * FROM "de youtube cleansed rh". "raw statistics" a
- 2 INNER JOIN "de youtube cleansed rh". "cleaned statistics reference data" b ON a.category id=b.id;







Glue ETL iş akışı (2) – Tabloların birleştirilmesi

- · iki tablo category_id üzerinden join edildi.
- Yeni oluşturulan tablo yeni database/bucket/tablo 'e aktarıldı.




SELECT * FROM "db_youtube analytics rh"."final analytics" limit 10;







Quicksight ile analiz sonuçlarının görselleştirilmesi

Athena kullanılarak database aktarıldı







Reyhan HoşavcıReyhan Hoşavcı Reyhan HoşavcıReyhan Hoşavcı Teşekkürler Reyhan HoşavcıReyhan Hoşavcı Reyhan HoşavcıReyhan Hoşavcı Reyhan HoşavcıReyhan Hoşavcı